



Grenoble INP – ENSIMAG
École Nationale Supérieure d'Informatique et de Mathématiques Appliquées

Rapport de projet de fin d'études

Effectué chez Thales

Improving WebUI user experience thanks to AI Voice-LLM

Elisabeth Berat
3e année – Option ISI

02 mars 2026 – 31 août 2026

Thales
Želetavská 1448/7,
140 00 Praha 4

Responsable de stage
Antoine GALLAND
Tuteur de l'école
Samir SADOK

Coordonnées

Elisabeth BERAT

+33 6 63 67 92 56

elisabeth.berat@grenoble-inp.org

Antoine GALLAND

antoine.galland@thalesgroup.com

Samir SADOK

samir.sadok@inria.fr

Table des matières

1	Glossary	5
2	Introduction	5
2.1	Présentation de la structure	6
3	Présentation du sujet de stage	6
3.1	Problématique	6
3.2	Objectifs	6
4	Solutions techniques	7
4.1	Etat de l'existant	7
4.2	Challenges	8
4.3	Protocole d'évaluation	8
5	Etat de l'avancement	9
5.1	Ce qui a été fait jusqu'à présent	9
5.2	Technologies et Architecture	10
5.3	Ce qu'il reste à faire	11
6	Impressions	12
7	Impact environmental et sociétal	13

Résumé

Ce projet de fin d'études, réalisé au sein de l'équipe Innovation de Thales à Prague, vise à améliorer l'expérience utilisateur des bornes d'enregistrement (kiosques) grâce à l'intégration de l'intelligence artificielle. L'objectif est de renforcer l'autonomie des usagers via un agent conversationnel multimodal, capable de traiter les interactions vocales pour adapter dynamiquement l'interface ou fournir une assistance basée sur la documentation technique. Ce travail repose sur le développement d'une architecture modulaire utilisant le [Multi-threading](#) pour garantir une faible latence, ainsi que sur l'implémentation de techniques de détection de la langue et de Retrieval-Augmented Generation ([RAG](#)). L'enjeu central réside dans la conception d'un système fluide et robuste, capable de fonctionner dans des environnements publics bruyants tout en respectant les contraintes de confidentialité des données.

Keywords— Intelligence Artificielle, Agent conversationnel, [RAG](#), Reconnaissance vocale, Expérience utilisateur

1 Glossary

LLM : Un Large Language Model est un système d'intelligence artificielle qui traite des données en langage naturel à l'aide de schémas complexes appris à partir d'énormes ensembles de données afin de générer une réponse pertinente et semblable à celle d'un humain, comme ChatGPT, Gemini ou Claude.

RAG : Retrieval-Augmented Generation est une méthode consistant à enrichir les réponses d'une IA en lui permettant de consulter une base de données externe, garantissant ainsi des informations précises, actualisées et spécifiques à un domaine.

front-end : Le front-end désigne la partie d'une application ou d'un site web avec laquelle l'utilisateur interagit directement. Il comprend tout ce qui est visible à l'écran : le design, les menus, les boutons et les formulaires.

multi-threading : Le multi-threading est une technique de programmation qui permet à un programme d'exécuter plusieurs tâches (ou "threads") simultanément au sein d'un même processus.

2 Introduction

Dans un monde de plus en plus numérisé, Thales propose des solutions sécurisées et efficaces pour accompagner la transition vers le numérique. Tournées vers l'avenir, ces idées ont souvent une longueur d'avance sur leur temps afin de révolutionner notre monde. Pour ce faire, l'objectif est d'utiliser les technologies de pointe de manière innovante afin d'améliorer tous les aspects de notre vie quotidienne. L'un des enjeux actuels pour le monde de demain consiste à trouver des applications de l'IA dans ces solutions.

De nombreuses solutions proposées par Thales sont utilisées par le grand public, comme les bornes destinées à la délivrance de documents officiels ou celles permettant de s'enregistrer dans les aéroports. L'efficacité de ces systèmes repose sur leur capacité à s'adapter en temps réel aux besoins et aux questions de chaque utilisateur afin de renforcer l'autonomie de ces derniers. C'est ici qu'intervient l'intelligence artificielle : elle permet de transformer l'interaction homme-machine pour la rendre plus intuitive, inclusive et réactive. Avec l'émergence de l'IA multimodale, la voix, les images, le texte et d'autres modalités peuvent être utilisés, multipliant ainsi les possibilités d'utilisation créative de l'IA dans ces solutions. Il est désormais possible de découvrir de nouvelles façons efficaces d'interagir avec l'utilisateur via l'interface, l'objectif étant d'améliorer le taux d'utilisation autonome.

Face à toutes ces possibilités d'intégration de l'IA, l'objectif est de trouver la manière la plus efficace de procéder en nous posant les questions suivantes : comment proposer une assistance vocale personnalisée ou adapter l'interface de manière dynamique ? Devrions-nous adapter le parcours utilisateur en fonction de la langue parlée ou encore détecter les signes de frustration ? Mon stage porte sur ces questions, dans le but de renforcer l'autonomie de l'utilisateur en mettant à sa disposition un agent intelligent capable de répondre de manière fluide et appropriée à divers cas d'utilisation.

2.1 Présentation de la structure

Thales est un leader mondial des hautes technologies, qui se structure en cinq unités appelées Business Units : IBS (Identity & Biometric Solutions), PAY (Payment Services), CPS (Cybersecurity Premium Services), CSP (Cyber Security Products) et MCS (Mobile & Connectivity Solutions). Le site de Prague, où se déroule mon stage, accueille principalement des activités liées à IBS et MCS. Ce centre joue un rôle important en tant que pôle d'innovation et de développement technique pour ces branches en regroupant notamment des équipes de recherche.

Mon stage se situe au sein de l'équipe Innovation répartie entre Prague et le site de Gémenos. Cette équipe se consacre à l'exploration de nouvelles technologies et à la création de prototypes pour anticiper les besoins futurs du marché. Je travaille en étroite collaboration avec l'équipe WES (Web Enrolment Systems) basée à Prague, car ce sont eux qui assurent le développement technologique des bornes d'enregistrement (kiosques) sur lesquelles mon projet se base. Mon stage se situe ainsi entre ces deux entités puisqu'il s'agit d'innovation sur la solution du kiosque.

Mon tuteur de stage au sein de Thales est le directeur de l'innovation technique au sein de l'équipe innovation à Gémenos, Antoine Galland. Afin d'avoir un accompagnement local, un tuteur basé à Prague m'a également été assigné. Il s'agit de Daniel De Santis, manager de l'équipe demo. L'environnement international de Thales pousse des équipes autour du monde à collaborer. Le siège basé aux Etats-Unis possède leur propre kiosque. Cette équipe étant très intéressée par mon projet, je travaille également avec eux.

3 Présentation du sujet de stage

3.1 Problématique

L'idée à l'origine de ce projet est d'intégrer progressivement l'IA dans les solutions de Thales. Il s'agit d'un premier pas dans cette direction. Nous nous concentrons ici sur l'expérience utilisateur à travers les différentes bornes que Thales propose comme solution pour un enregistrement efficace (par exemple, dans les aéroports) ou le renouvellement de documents. L'objectif est d'augmenter le nombre d'utilisations autonomes du kiosque. Pour ce faire, différentes approches sont étudiées. Mon objectif pendant ce stage est de développer et de tester des idées innovantes pour créer un agent à partir de zéro, destiné à être intégré aux différentes bornes de Thales. Je dois trouver la meilleure façon d'interagir avec l'utilisateur, choisir les technologies et tester l'agent dans des conditions proches de celles d'un cas d'utilisation réel. Jusqu'à présent, deux cas d'utilisation principaux ont été définis à l'issue de discussions avec différents membres de Thales.

3.2 Objectifs

À la fin du stage, l'objectif est de disposer d'une PoC pouvant servir à présenter le concept à différents publics. Elle doit donc être finalisée et testée de manière approfondie dans diverses conditions.

Le premier cas d'utilisation consiste à détecter la langue utilisée par l'utilisateur afin d'adapter l'interface en conséquence. L'idée est de détecter la langue d'un utilisateur se trouvant devant la borne interactive et de s'en servir pour modifier directement la langue de l'interface. Une question reste en suspens : quelle est la manière la plus efficace d'inviter un utilisateur à parler devant le kiosque ? Pour ce cas d'utilisation, l'entrée est la voix et la sortie est la modification de l'interface utilisateur.

Le deuxième cas d'utilisation consiste à développer un assistant qui utilise la documentation d'aide du kiosque pour guider l'utilisateur. Cette documentation sera utilisée pour constituer un [RAG](#). L'entrée reste vocale mais la sortie pourrait prendre la forme de texte ou d'une modification de l'interface. Ce point n'est pas encore défini et devra être étudié en fonction de la faisabilité, de la pertinence et de l'avancement du projet.

Ce sont là les principaux cas d'utilisation prioritaires. En fonction de la rapidité de mise en œuvre, ces cas d'utilisation pourraient être approfondis ou d'autres cas pourraient être développés. Afin de réaliser des tests simples, je vais mettre en place une interface utilisateur de démonstration qui reproduira de manière simplifiée l'interface utilisateur du kiosque. L'objectif final est de tester l'application sur le [front-end](#) réel du kiosque. Par ailleurs, aux États-Unis, une version du kiosque est utilisée. Chaque année, une démonstration est organisée pour démontrer les nouvelles fonctionnalités du kiosque. Cette année, cette démonstration a lieu en septembre, ce qui tombe à point nommé pour présenter l'assistant développé pendant le stage. C'est donc également l'un des objectifs.

4 Solutions techniques

4.1 Etat de l'existant

Un projet similaire au sujet de mon stage avait été initié il y a environ un an, aboutissant en une preuve de concept (PoC) centrée sur une interaction vocale bidirectionnelle. L'architecture est conçue de manière modulaire, structurée autour d'une pipeline en trois étapes distinctes : une phase de Speech-to-Text (STT) pour la transcription de la voix de l'utilisateur, une transmission du texte vers un [LLM](#) pour le traitement du langage naturel, et enfin une phase de Text-to-Speech (TTS) pour la synthèse vocale.

Cette solution se distingue par sa flexibilité, permettant de basculer entre une architecture cloud et une architecture locale pour s'adapter aux besoins du terrain. De plus, l'implémentation inclut un mécanisme de [RAG](#), pour permettre à l'agent d'accéder dynamiquement à des connaissances métiers spécifiques et d'apporter des réponses contextualisées, plutôt que de se reposer uniquement sur les données d'entraînement statiques du modèle.

Cette PoC permet de constituer une base solide d'inspiration. Pour autant, comme prévu lors du recrutement, mon projet sera commencé de zéro. En effet, les technologies d'IA évoluant rapidement et les besoins du projet ayant depuis été clarifiés et modifiés, il était plus intéressant de reprendre d'une base vierge.

Une autre preuve de concept reprenant exactement le principe de la première a été mise en œuvre, la seule différence étant que celle-ci était destinée à fonctionner sur un matériel embarqué. Ce projet a finalement été abandonné.

Des modèles existants seront utilisés pour ce projet. Il sera peut-être question de fine-tuning ou de prompt-engineering si besoin.

4.2 Challenges

Cette application de l'IA dans un kiosque destiné à être utilisé dans un espace public pose plusieurs défis. Tout d'abord, il y a le bruit. En effet, notre premier cas d'utilisation consiste à changer la langue en fonction de la parole de l'utilisateur. Dans un aéroport, il y a beaucoup de gens qui parlent dans de nombreuses langues différentes. L'un des défis consistera à trouver une solution de débruitage adaptée à nos besoins afin d'éviter que la borne ne détecte tous les bruits environnants comme de la parole et ne surcharge les modèles de requêtes, mais aussi pour empêcher que la langue ne change à chaque fois qu'une personne parlant une autre langue passe à proximité. Le débruitage pourrait induire une latence s'il est trop lourd. Il faudra donc étudier un compromis à cet égard.

Un deuxième défi consistera à réduire autant que possible la latence. Pour garantir une interaction fluide avec l'utilisateur, la latence doit être suffisamment faible. Si la latence est trop élevée, l'utilisateur risque de ne pas comprendre ce qui se passe et, au lieu de l'aider, nous risquons de le rendre encore plus désorienté et frustré.

Enfin, cette application d'assistance sera conçue pour s'intégrer à des bornes interactives traitant des informations personnelles. La confidentialité doit être prise en compte dès la conception, d'autant plus que nous utilisons la voix comme entrée.

Ce projet s'inscrivant dans une démarche d'innovation, la conception de l'application et la manière dont on répond aux cas d'utilisation relèvent de ma responsabilité. Je dois choisir judicieusement toutes les technologies afin de répondre au mieux aux défis mentionnés ci-dessus.

4.3 Protocole d'évaluation

Afin de mesurer l'efficacité de ma solution, j'ai défini plusieurs indicateurs que je dois évaluer :

- La latence : tant au niveau global que local, la latence constituera un indicateur clé à évaluer. En effet, je souhaite mesurer la latence globale de mon système, mais je veux également identifier les parties de l'application les plus lentes afin de déterminer les points à améliorer. L'objectif est d'atteindre un niveau de latence suffisamment bas pour que l'interaction avec l'utilisateur soit au plus près de la fluidité d'une conversation avec un être humain.

- Le seuil de silence : dans mon application, j'utilise un seuil de silence pour détecter le moment où l'utilisateur a vraisemblablement cessé de parler. Si ce seuil est trop élevé, cela entraînera une latence ; s'il est trop bas, l'enregistrement s'arrêtera alors que l'utilisateur fait une pause naturelle dans sa phrase. C'est pourquoi il est essentiel de trouver le juste équilibre. Pour ce faire, je prévois de consulter la documentation disponible sur le sujet et de sélectionner trois valeurs qui semblent cohérentes pour ma mise en œuvre. Ensuite, je demanderai à mes collègues de bureau de tester l'application avec ces trois valeurs différentes et de choisir celle qui leur convient le mieux.
- Je souhaiterais également évaluer le taux de faux déclenchements dus au bruit ambiant ou aux conversations environnantes, ainsi que les erreurs de reconnaissance de la langue. Concernant le premier point, j'aimerais tester mon application dans plusieurs conditions de bruit ambiant afin de déterminer quelles situations doivent être prises en compte et à partir de quel niveau de bruit cela ne pose plus de problème. Cela sera difficile à reproduire. De plus, comme je n'ai pas accès au matériel exact (microphone, haut-parleurs), cela complique les tests, mais d'un autre côté, si j'identifie un besoin spécifique, je pourrai en faire la demande avant que nous ne choisissons le matériel définitif. Je ne peux pas vraiment agir sur les erreurs de détection de la langue, mais si le taux est trop élevé, je pourrais trouver un moyen d'améliorer la situation (changer de modèle, utiliser une approche différente...).

Afin de tester tous les éléments mentionnés au-dessus, j'ai développé une petite interface utilisateur inspirée de la logique de l'interface du kiosque. Je dois élaborer un protocole précis pour ensuite pouvoir soumettre mes collègues à des tests reproductibles.

5 Etat de l'avancement

5.1 Ce qui a été fait jusqu'à présent

Les trois premières semaines de mon stage ici ont été consacrées à rassembler des informations sur l'état d'avancement du projet. En effet, avant mon arrivée, mon tuteur avait découvert qu'une équipe aux États-Unis s'intéressait au projet de mon stage et avait lancé un projet similaire (mentionné à la section 4.1). J'ai donc dû me mettre à jour d'abord sur le code, puis sur les personnes qui y travaillaient, afin de comprendre ce qui avait été fait et comment. Thales étant une grande structure, j'ai dû contacter différentes équipes de recherche. Enfin, j'ai dû rencontrer l'équipe intéressée par mon application et comprendre ses besoins. Tout cela a été réalisé avec le soutien de mon tuteur.

Au cours de la troisième semaine, j'avais fini de comprendre le code et j'en savais suffisamment pour commencer à travailler sur ma propre implémentation. À l'issue de la quatrième semaine, je savais quels étaient les objectifs poursuivis par l'équipe américaine. Une démonstration était prévue en septembre sur le kiosque américain. Cela a ajouté un objectif très intéressant à mon stage, car j'ai désormais une démonstration concrète à réaliser. En raison des règles de confidentialité en vigueur aux États-Unis, je n'ai pas accès au code de leur kiosque, ce qui complique la conception



FIGURE 1 – Simplified User Interface

de la communication avec le [front-end](#). Heureusement, l'équipe de recherche qui travaille sur la mise en œuvre du kiosque et dont le code a été tiré est basée à Prague. J'ai donc pu accéder à leur code et me faire une idée précise de ce à quoi ressemble la borne aux États-Unis.

À l'heure actuelle, j'ai mis en place un assistant de reconnaissance vocale utilisant une architecture modulaire : j'utilise un premier modèle pour effectuer la transcription vocale, puis j'envoie cette transcription à un [LLM](#). Maintenant que j'ai accès au code du kiosque ici à Prague, j'ai pu mettre en place une version très simplifiée de leur interface utilisateur afin de tester facilement comment mon application d'assistant peut communiquer avec leur interface (voir Figure 1). Après discussion avec l'équipe en charge du kiosque, nous avons convenu d'utiliser WebSocket pour déclencher un changement de langue de leur côté. C'est donc ce que j'ai mis en place pour communiquer avec mon interface de démonstration.

Je peux m'exprimer en français et en anglais, et l'interface utilisateur de démonstration adaptera sa langue en conséquence. Je n'utilise pas encore la partie [LLM](#) de l'approche modulaire, mais elle sera utile pour le deuxième cas d'utilisation. Afin de déterminer la langue de la saisie de l'utilisateur, j'ai envisagé deux solutions : je peux utiliser le modèle Whisper-1 d'OpenAI, qui inclut la détection de la langue dans sa transcription, ou bien ajouter dans le prompt du [LLM](#) la tâche spécifique consistant à récupérer la langue. Pour l'instant, j'utilise la première option, mais la seconde pourrait s'avérer utile au cas où Whisper ne serait pas disponible.

5.2 Technologies et Architecture

L'application est divisée en plusieurs classes et utilise le [Multi-threading](#) pour exécuter les tâches en parallèle :

- **Listener** : Le premier thread implémente cette classe. Il constitue la partie « écoute » de l'application. La voix en entrée est traitée sous forme de flux afin de réduire la latence. Le VAD (Voice Activity Detection) de Silero est également utilisé pour permettre une conver-

sation fluide avec l'assistant. Il permet de détecter les silences dans la parole à l'aide d'un réseau neuronal spécialement formé à cet effet. Ce thread appelle une instance de la classe « transcrire » pour obtenir la transcription de la parole en entrée et la placer dans une file d'attente.

- **Transcriber** : Cette classe fait appel à un modèle de reconnaissance vocale afin d'obtenir une transcription de la commande vocale de l'utilisateur. En utilisant Whisper (un modèle d'OpenAI dédié à la transcription vocale), il est possible d'obtenir directement la langue détectée.
- **LLMAssistant** : Il s'agit de la classe mise en œuvre par le deuxième thread. Parallèlement au thread Listener avec lequel il partage une file d'attente, ce thread envoie la transcription récupérée dans la file à un **LLM** et récupère sa réponse. Cette partie sera utile lors du traitement du deuxième cas d'utilisation. J'ai implémenté un historique afin que le **LLM** puisse suivre la conversation. Comme la fenêtre de contexte du **LLM** a une taille limitée, j'ai également implémenté une logique permettant de vider l'historique lorsqu'il s'approche trop de la limite.

En plus de la liste ci-dessus, un client WebSocket utilisé pour communiquer avec l'interface utilisateur a été mis en œuvre (voir la figure 2 pour une représentation schématique de l'architecture). L'application est codée en Python pour le back-end et en JavaScript pour l'interface utilisateur. Les technologies utilisées pour la mise en œuvre sont les suivantes :

- Pour le traitement audio, j'utilise sounddevice pour la capture en temps réel du signal du microphone et soundfile pour l'encodage du format audio,
- Pour la détection d'activité vocale, j'utilise Silero VAD, que je charge et appelle via PyTorch,
- Pour gérer les appels vers les modèles sur le cloud, j'utilise le SDK OpenAI et LiteLLM,
- Enfin, j'utilise l'API WebSocket pour communiquer avec l'interface utilisateur.

5.3 Ce qu'il reste à faire

Pour le premier cas d'utilisation, je travaille actuellement sur un exemple simple d'interface utilisateur. Je dois poursuivre les tests pour voir si je peux améliorer la latence, même si je le prends en compte depuis le début et que celle-ci est assez bonne pour l'instant. Je dois également faire des tests supplémentaires avec des personnes qui n'ont pas travaillé sur le code pour vérifier si elles parviennent à l'utiliser correctement : pas d'interruption de la parole par l'assistant, conversation fluide... Mon principal problème pour l'instant est le débruitage. Le kiosque sera utilisé dans un endroit bruyant (un aéroport, par exemple). Je dois trouver un moyen pour que la détection de la langue soit cohérente et ne change pas à chaque fois que quelqu'un passe à proximité.

Je n'ai pas encore commencé à travailler sur le deuxième cas d'utilisation. Le pipeline est déjà

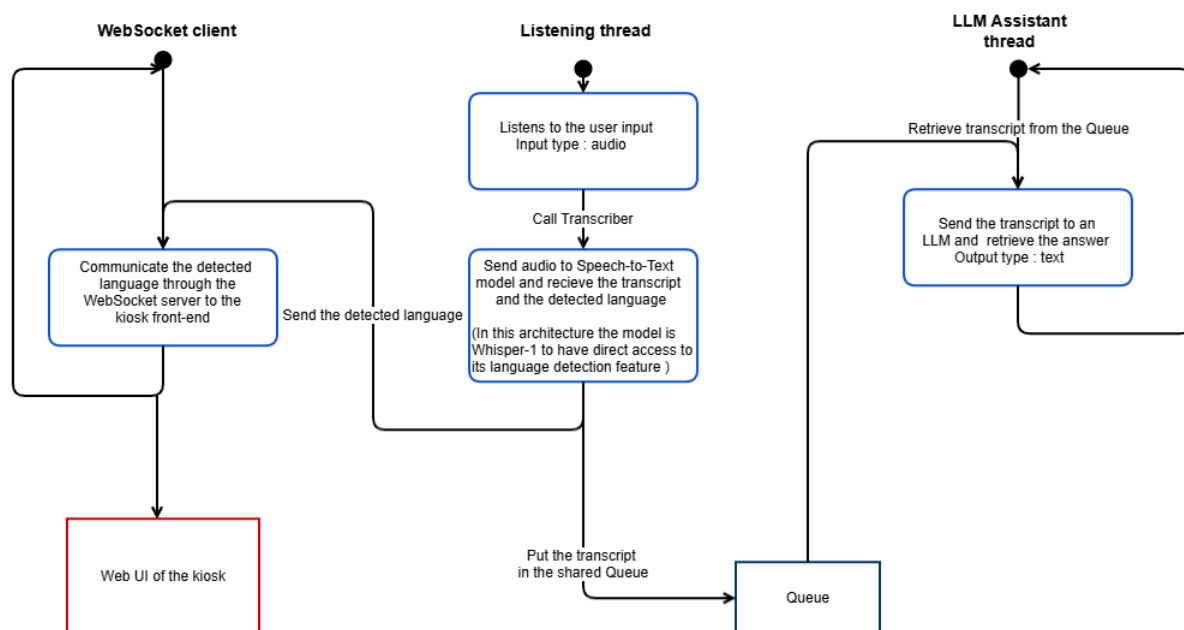


FIGURE 2 – Schéma de l'architecture de l'application

en place, mais je n'ai pour l'instant pas commencé à trqvqiller sur le [RAG](#).

De plus, une grande partie du travail consistera à tester l'application sur le kiosque réel afin de vérifier si elles s'intègrent correctement.

6 Impressions

Ces premières semaines sont passées très vite. J'ai l'impression d'avoir déjà beaucoup appris. C'est la première fois que je me lance dans un projet d'une telle envergure en partant de zéro, mais le principal changement, c'est de le faire au sein d'une grande entreprise. C'est très agréable de pouvoir consacrer tout mon temps de travail à un seul projet. Mon premier stage était à temps partiel pendant mon master et mon projet de recherche se déroulait également en parallèle de mes cours, donc j'apprécie vraiment de n'avoir que ce projet en tête. Je peux prendre le temps de faire les choses et d'apprendre, ce qui est très agréable.

Le premier défi à mon arrivée ici a été de m'habituer aux différents outils utilisés dans l'entreprise. Puis, j'ai réalisé que travailler dans une entreprise internationale présentait aussi des inconvénients en matière de communication. J'ai dû contacter de nombreuses personnes pour obtenir les informations dont j'avais besoin. Cela m'a pris un certain temps, mais cela m'a permis de rencontrer différentes personnes impliquées dans mon projet.

Une journée type ici commence par une réunion quotidienne le matin avec l'équipe de demo, au

cours de laquelle nous faisons le point sur ce que nous avons accompli jusqu'à présent et évoquons les difficultés rencontrées, le cas échéant. Je passe ensuite la majeure partie de mon temps à travailler sur mon application. Plusieurs autres stagiaires travaillent sur l'IA, ce qui nous permet d'échanger quotidiennement, à l'heure du déjeuner, sur les difficultés rencontrées, les solutions trouvées et les idées qui nous viennent.

7 Impact environmental et sociétal

La majeure partie de l'activité liée à ce stage repose sur le développement logiciel reposant sur un ordinateur de travail et l'accès aux infrastructures du site de Prague (éclairage, climatisation, chauffage des locaux). Bien que l'entraînement initial de certains modèles d'IA soit énergivore, mon travail s'est concentré sur l'optimisation d'agents conversationnels légers et l'utilisation de serveurs communs.

Les échanges avec les équipes situées à Gémenos, aux États-Unis et au Canada ont été exclusivement réalisés via Teams. Aucun déplacement physique n'a été nécessaire pour le moment.

Depuis mon arrivée au sein de Thales, nous avons eu une formation sur les designs écologiques et les outils développés par Thales pour tester l'impact de nos codes. Un agenda d'objectifs pour 2030 concernant le développement durable est également en vigueur.